Tarea Estadística Computacional Sofia Gerard

2023-10-12

```
flights
## # A tibble: 336,776 x 19
                     day dep_time sched_dep_time dep_delay arr_time sched_arr_time
       year month
##
      <int> <int>
                   <int>
                             <int>
                                              <int>
                                                        <dbl>
                                                                  <int>
                                                                                   <int>
##
    1
       2013
                        1
                               517
                                                515
                                                             2
                                                                    830
                                                                                     819
##
    2 2013
                               533
                                                529
                                                             4
                                                                    850
                                                                                     830
                 1
                        1
    3
       2013
                                                             2
##
                 1
                        1
                               542
                                                540
                                                                    923
                                                                                     850
##
    4
       2013
                                                545
                                                                   1004
                                                                                    1022
                 1
                        1
                               544
                                                            -1
       2013
##
    5
                 1
                        1
                               554
                                                600
                                                            -6
                                                                    812
                                                                                     837
##
    6 2013
                        1
                               554
                                                558
                                                            -4
                                                                    740
                                                                                     728
##
    7 2013
                       1
                               555
                                                600
                                                            -5
                                                                    913
                                                                                     854
                 1
       2013
                                                                                     723
##
                 1
                        1
                               557
                                                600
                                                            -3
                                                                    709
##
    9
       2013
                        1
                               557
                                                600
                                                            -3
                                                                    838
                 1
                                                                                     846
## 10
       2013
                 1
                        1
                               558
                                                600
                                                            -2
                                                                    753
                                                                                     745
## # i 336,766 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
       tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
       hour <dbl>, minute <dbl>, time_hour <dttm>
summary(flights)
```

```
##
         year
                        month
                                            day
                                                           dep_time
                                                                        sched_dep_time
##
    Min.
            :2013
                    Min.
                            : 1.000
                                      Min.
                                              : 1.00
                                                       Min.
                                                               :
                                                                       Min.
                                                                               : 106
                                                                   1
    1st Qu.:2013
                    1st Qu.: 4.000
                                      1st Qu.: 8.00
                                                       1st Qu.: 907
                                                                        1st Qu.: 906
    Median:2013
                    Median : 7.000
                                      Median :16.00
                                                       Median:1401
                                                                       Median:1359
##
##
    Mean
            :2013
                    Mean
                            : 6.549
                                      Mean
                                              :15.71
                                                       Mean
                                                               :1349
                                                                       Mean
                                                                               :1344
##
    3rd Qu.:2013
                    3rd Qu.:10.000
                                      3rd Qu.:23.00
                                                       3rd Qu.:1744
                                                                        3rd Qu.:1729
##
    Max.
            :2013
                    Max.
                            :12.000
                                      Max.
                                              :31.00
                                                       Max.
                                                               :2400
                                                                       Max.
                                                                               :2359
##
                                                       NA's
                                                               :8255
##
      dep_delay
                                       sched_arr_time
                                                          arr delay
                          arr_time
                                                       Min.
##
           : -43.00
                                       Min.
                                             :
                                                               : -86.000
    Min.
                             :
                                                   1
                       Min.
    1st Qu.:
              -5.00
                       1st Qu.:1104
                                       1st Qu.:1124
                                                       1st Qu.: -17.000
##
    Median :
              -2.00
                       Median:1535
                                       Median:1556
                                                       Median:
                                                                  -5.000
    Mean
             12.64
                       Mean
                               :1502
                                       Mean
                                               :1536
                                                       Mean
                                                                   6.895
##
    3rd Qu.: 11.00
                       3rd Qu.:1940
                                                       3rd Qu.: 14.000
                                       3rd Qu.:1945
            :1301.00
                                               :2359
                                                               :1272.000
    Max.
                       Max.
                               :2400
                                       Max.
                                                       Max.
    NA's
            :8255
                       NA's
                                                       NA's
##
                               :8713
                                                               :9430
##
      carrier
                            flight
                                          tailnum
                                                                origin
                                        Length: 336776
##
    Length: 336776
                        Min.
                                                             Length: 336776
    Class : character
                        1st Qu.: 553
                                        Class : character
                                                             Class : character
##
    Mode :character
                        Median:1496
                                        Mode
                                              :character
                                                             Mode :character
##
                        Mean
                                :1972
                        3rd Qu.:3465
##
##
                        Max.
                                :8500
```

##

```
##
       dest
                        air_time
                                       distance
                                                       hour
                     Min. : 20.0 Min. : 17
                                                        : 1.00
## Length:336776
                                                  \mathtt{Min}.
                     1st Qu.: 82.0
  Class :character
                                    1st Qu.: 502
                                                  1st Qu.: 9.00
## Mode :character Median :129.0
                                    Median: 872
                                                  Median :13.00
##
                     Mean
                           :150.7
                                    Mean :1040
                                                  Mean :13.18
##
                     3rd Qu.:192.0
                                    3rd Qu.:1389
                                                  3rd Qu.:17.00
##
                     Max.
                            :695.0
                                    Max. :4983
                                                  Max. :23.00
                            :9430
                     NA's
##
##
       minute
                    time_hour
  Min. : 0.00
                        :2013-01-01 05:00:00.00
##
                  Min.
   1st Qu.: 8.00
                 1st Qu.:2013-04-04 13:00:00.00
## Median :29.00
                 Median :2013-07-03 10:00:00.00
## Mean
         :26.23
                 Mean
                        :2013-07-03 05:22:54.64
## 3rd Qu.:44.00
                  3rd Qu.:2013-10-01 07:00:00.00
## Max. :59.00 Max.
                        :2013-12-31 23:00:00.00
##
str(flights)
## tibble [336,776 x 19] (S3: tbl_df/tbl/data.frame)
                  $ year
                  : int [1:336776] 1 1 1 1 1 1 1 1 1 1 ...
##
   $ month
## $ day
                  : int [1:336776] 1 1 1 1 1 1 1 1 1 1 ...
## $ dep_time
                 : int [1:336776] 517 533 542 544 554 554 555 557 557 558 ...
## $ sched_dep_time: int [1:336776] 515 529 540 545 600 558 600 600 600 600 ...
                : num [1:336776] 2 4 2 -1 -6 -4 -5 -3 -3 -2 ...
## $ dep_delay
## $ arr_time
                  : int [1:336776] 830 850 923 1004 812 740 913 709 838 753 ...
## $ sched arr time: int [1:336776] 819 830 850 1022 837 728 854 723 846 745 ...
                 : num [1:336776] 11 20 33 -18 -25 12 19 -14 -8 8 ...
## $ arr_delay
## $ carrier
                  : chr [1:336776] "UA" "UA" "AA" "B6" ...
## $ flight
                  : int [1:336776] 1545 1714 1141 725 461 1696 507 5708 79 301 ...
## $ tailnum
                  : chr [1:336776] "N14228" "N24211" "N619AA" "N804JB" ...
                  : chr [1:336776] "EWR" "LGA" "JFK" "JFK" ...
## $ origin
## $ dest
                  : chr [1:336776] "IAH" "IAH" "MIA" "BQN" ...
## $ air_time
                : num [1:336776] 227 227 160 183 116 150 158 53 140 138 ...
                 : num [1:336776] 1400 1416 1089 1576 762 ...
## $ distance
                  : num [1:336776] 5 5 5 5 6 5 6 6 6 6 ...
## $ hour
                  : num [1:336776] 15 29 40 45 0 58 0 0 0 0 ...
##
   $ minute
                  : POSIXct[1:336776], format: "2013-01-01 05:00:00" "2013-01-01 05:00:00" ...
## $ time_hour
dim(flights)
## [1] 336776
                19
```

Aerolíneas más retrasadas

```
arrange(desc(mean_dep_delay)) |>
select(carrier, mean_dep_delay) |>
head(10)

cat("Las 10 aerolíneas que más se retrasan al salir en promedio son:", head(max_dep_delay$carrier, 10))

## Las 10 aerolíneas que más se retrasan al salir en promedio son: F9 EV YV FL WN 9E B6 VX 00 UA

# Arrival

max_arr_delay <- retrasos_aerolineas %>%
arrange(desc(mean_arr_delay)) |>
select(carrier, mean_arr_delay) |>
head(10)


cat("Las 10 aerolíneas que más se retrasan al llegar en promedio son:", head(max_dep_delay$carrier, 10)
```

Las 10 aerolíneas que más se retrasan al llegar en promedio son: F9 EV YV FL WN 9E B6 VX 00 UA

Distribuciones del retraso


Warning: Removed 8255 rows containing non-finite values (`stat_bin()`).

Distribución de Retrasos de Salida



Warning: Removed 9430 rows containing non-finite values (`stat_bin()`).

Distribución de Retrasos de Llegada



El avion más retrasado

Los 10 aviones que más se retrasan al salir en promedio son: N844MH N922EV N587NW N911DA N851NW N654

```
max_arr_delay_avion <- aviones %>%
   arrange(desc(mean_arr_delay)) |>
   select(tailnum, mean_arr_delay) |>
   head(10)

cat("Los 10 aviones que más se retrasan al llegar en promedio son:", head(max_arr_delay_avion$tailnum,
```

Los 10 aviones que más se retrasan al llegar en promedio son: N844MH N911DA N922EV N587NW N851NW N92

Avión que más recorrió, el top 10 distancia, viajes

```
distancia <- flights %>%
  select(tailnum, distance) %>%
  group_by(tailnum) %>%
  summarize(media_distancia = mean(distance)) %>%
  arrange(desc(media_distancia))

cat("Los 10 aviones que más distancia han recorrido son:", head(distancia$tailnum, 10))
```

Los 10 aviones que más distancia han recorrido son: N380HA N381HA N382HA N383HA N384HA N385HA N386HA

¿Los vuelos están vinculados a la ruta?

```
vuelos_rutas <- flights %>%
  select(flight, origin, dest) %>%
  group_by(flight) %>%
  arrange(flight)

# Parece ser que para un mismo vuelo hay distintas rutas. Pero siempre son
# las mismas 5-6 rutas.
```

Frecuencia de retrasos por hora

```
flights_hora <- flights %>%
  mutate(time_hour = format(time_hour, format = "%H:%M")) %>%
  select(time_hour, arr_delay, dep_delay) %>%
  group_by(time_hour) %>%
  summarize(mean_dep_delay = mean(dep_delay, na.rm = TRUE),
             mean_arr_delay = mean(arr_delay, na.rm = TRUE))
# Departure
max_dep_delay_hora <- flights_hora %>%
  arrange(desc(mean_dep_delay)) |>
  select(time_hour, mean_dep_delay)
gg1 <- ggplot(max_dep_delay_hora, aes(x = time_hour, y = mean_dep_delay)) +</pre>
  geom bar(stat = "identity", fill = "blue") +
  labs(title = "Máximo Retraso Promedio en la Salida por Hora",
       x = "Hora del Día",
       y = "Máximo Retraso en la Salida (minutos)") +
  theme_minimal()
# Arrival
max_arr_delay_hora <- flights_hora %>%
 arrange(desc(mean_arr_delay)) |>
  select(time_hour, mean_arr_delay)
gg2 <- ggplot(max_arr_delay_hora, aes(x = time_hour, y = mean_arr_delay)) +</pre>
  geom_bar(stat = "identity", fill = "red") +
  labs(title = "Máximo Retraso Promedio en la Llegada por Hora",
       x = "Hora del Día",
       y = "Máximo Retraso en la Llegada (minutos)") +
  theme minimal()
```

Hay diferencia por aeropuerto en retrasos

```
# Aeropuerto Origin
aeropuertos_origin <- flights %>%
    select(origin, dep_delay) %>%
    group_by(origin) %>%
    summarize(mean_dep_delay = mean(dep_delay, na.rm = TRUE)) %>%
    arrange(desc(mean_dep_delay))

# Aeropuerto Destination
aeropuertos_destination <- flights %>%
    select(dest, arr_delay) %>%
    group_by(dest) %>%
    summarize(mean_arr_delay = mean(arr_delay, na.rm = TRUE)) %>%
    arrange(desc(mean_arr_delay))
```

Para el aeropuerto origen, el que más se atrasa en promedio es EWR (15.1), mientras que el aeropuerto destino con más retrasos en promedio es CAE (41.8).

Hay diferencia por mes

```
por_mes <- flights %>%
  select(month, dep_delay, arr_delay) %>%
  group_by(month) %>%
   summarize(mean_dep_delay = mean(dep_delay, na.rm = TRUE),
             mean_arr_delay = mean(arr_delay, na.rm = TRUE))
# Departure
max dep delay month <- por mes %>%
  arrange(desc(mean_dep_delay)) |>
  select(month, mean_dep_delay) |>
 head(10)
cat("El peor mes para salidas, en promedio (más horas de retraso) es:",
   max(max_dep_delay_month$month))
## El peor mes para salidas, en promedio (más horas de retraso) es: 12
# Arrival
max_arr_delay_month <- por_mes %>%
  arrange(desc(mean_arr_delay)) |>
  select(month, mean_arr_delay) |>
 head(10)
```

El peor mes para llegadas, en promedio (más horas de retraso) es: 12

cat("El peor mes para llegadas, en promedio (más horas de retraso) es:",

Cuál es el peor vuelo

max(max_arr_delay_month\$month))

```
peores_vuelos <- flights %>%
    select(flight, dep_delay, arr_delay) %>%
```

```
group_by(flight) %>%
   summarize(mean_dep_delay = mean(dep_delay, na.rm = TRUE),
            mean_arr_delay = mean(arr_delay, na.rm = TRUE))
 # Departure
max_dep_delay_peor_vuelo <- peores_vuelos %>%
  arrange(desc(mean_dep_delay)) |>
  select(flight, mean dep delay) |>
  head(10)
# Arrival
max arr delay peor vuelo <- peores vuelos %>%
  arrange(desc(mean_arr_delay)) |>
  select(flight, mean_arr_delay) |>
  head(10)
tb_inter <- inner_join(max_dep_delay_peor_vuelo, max_arr_delay_peor_vuelo, by = "flight")
flights |> filter(flight == 1510)
## # A tibble: 1 x 19
                  day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##
      year month
##
     <int> <int> <int>
                          <int>
                                         <int>
                                                    <dbl>
                                                             <int>
                                                                            <int>
## 1 2013
              12
                           1823
                                          1345
                                                      278
                                                              2123
                                                                             1640
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
       tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #
       hour <dbl>, minute <dbl>, time_hour <dttm>
EL peor vuelo es el 1510 de EWR a IAH.
```

Cuál es el peor día de la semana para volar

```
arrange(desc(mean_arr_delay)) |>
select(dia_semana, mean_arr_delay)
```

El peor día para volar en terminos de horas de atraso promedio es jueves.